


Die Tanic EDA

2023. 06. 29. DATE NO.

data.pclass, data.survived 이항성보다
data['Sex'], data['Pclass'] 추천함
가시성이 훨씬 좋아요.

>> Crosstab → sns.factorplot 으로 가시화
(or group by랑 비슷.)

이제 안써 → catplot



Pclass feature는 종속변수
유의미해!

target과의 연관성.

>>

Age같은 연속형 값은 히스토그램을 많이 그린다.

왜냐하면 연속형인 kdeplot을 이용하자. 가우시안 커널.

Null값을 해결할 때 groupby를 해서 평균을 구해 넣어주면 좋겠네.

Feature engineering은 데이터를 분석해서 인사이트를 얻거나
무엇가 가치 있는 것을 가지고 파악해 산출하는 거고 그것을 토대로 넣어주고
학습을 해서 어떤 성능을 얻는 거.

>>


feature를 변경해줬을 때 주의할 점은 'inplace = True'를 지정해서
원래 값이 되는 방법이 있고, 다른 방법으로는 변수 안에 넣는 거이다.

>


```
data.loc[(data.Age.isnull()), :]
```

location 안에 mask (조건)을 넣으면 참을 판독한다.

1. data (is null(), same)
2. EDA
3. 교차검증 system.
(Cross Validation)



>> Feature generation과 Cross-validation은 함께 해야 한다.



K-fold

Loop

Up

→ CV와 LB가 같이 움직인다.
좋은 교차검증 결과는 좋은 feature가 있다.

(CV와 LB가 비현실적이게 잘 움직이는

교차검증 system 만드자.